Cuaderno 03 · Limpieza y mapeo de variables

Expediente: BES-jun · **Cuaderno:** 4 de 7 · **Estado del expediente:** Listo para revisión (no Completo)

1. Introducción y contexto (el problema)

Los datos están en un formulario, no en una tabla. Para calcular, graficar y auditar hace falta una estructura donde **cada número tenga nombre, unidad, tipo (dato o fórmula) y la celda exacta de la que salió**. Si la conversión pierde esa procedencia, un valor sospechoso ya no puede rastrearse hasta su origen, y si «limpia» valores sin dejar registro, se destruye evidencia.

2. Justificación y necesidad

Una tabla larga (hoja × variable) con procedencia por celda, un registro de unidades que **señale** los rótulos engañosos sin corregirlos en silencio, y una política de transformaciones explícita y comprobable: qué se hizo y, sobre todo, qué **no** se hizo.

3. Objetivo general

Generar los archivos de variables y unidades del expediente y demostrar, con una prueba de ida y vuelta contra el libro, que ningún valor fue alterado.

4. Dominio y alcance

Incluye: 34 variables por hoja (entradas de operación, parámetros mecánicos, de fluido y de bomba, límites escritos, resultados de la hoja); celda de origen, tipo de celda y unidad rotulada; identificadores (hoja, Cluster, Pozo); comparación de los datos de prueba con los de operación; escritura de CSV y su relectura.

No incluye: convertir unidades, imputar faltantes, normalizar, redondear ni «corregir» valores; unir hojas en un solo registro (cada hoja es un punto de operación, no una serie); elegir la llave del registro (CT-01).

5. Fuentes y datos (entradas y salidas)

Entrada: `entrada/BES_jun.xlsx`. **Salidas:** `data_procesados/variables_largo.csv`, `data_procesados/matriz_entradas_por_hoja.csv`, `data_procesados/registro_unidades.csv`.

6. Objetivos específicos y criterios de aceptación

C03-1 170 filas (34 variables × 5 hojas) y ninguna celda sin encontrar · **C03-2** los valores del mapeo coinciden con los del lector del cuaderno 04 · **C03-3** la prueba de ida y vuelta contra el libro no encuentra diferencias · **C03-4** los CSV releídos coinciden con lo escrito · **C03-5** toda variable tiene unidad rotulada o está declarada adimensional · **C03-6** el libro no cambió.

7. Riesgo si este paso falla

Un valor mal asignado a una variable (el caudal de prueba por el de operación, un caché por un dato) contamina todo el cálculo. Si la tabla no conserva la celda de origen, el error no se puede encontrar; si el «mapeo» modificó valores, tampoco se puede saber cuál era el dato real.

Preparación del entorno

Misma celda que en los demás cuadernos. Se guarda la huella del libro antes de empezar para demostrar al final que no cambió.

Código

```
from pathlib import Path
import os, sys

def localizar_expediente() -> Path:
    # Sube desde el directorio actual hasta la carpeta que tiene dataset.md y entrada/.
    for p in [Path.cwd().resolve(), *Path.cwd().resolve().parents]:
        if (p / "dataset.md").is_file() and (p / "entrada").is_dir():
            return p
    raise RuntimeError("Ejecute el cuaderno dentro del expediente (donde están dataset.md y entrada/).")

RAIZ = localizar_expediente()                # .../datasets/en_uso/BES-jun
RAIZ_PROYECTO = RAIZ.parents[2]              # .../HUC
os.chdir(RAIZ)
sys.path.insert(0, str(RAIZ / "src"))

import pandas as pd
pd.set_option("display.max_columns", None)
pd.set_option("display.width", 180)
pd.set_option("display.max_colwidth", None)
pd.set_option("display.float_format", lambda v: f"{v:,.8g}")

from analisis.criterios import Criterios
from analisis.entorno import ficha
from analisis.presentacion import T
T(pd.DataFrame(list(ficha().items()), columns=["campo", "valor"]))
```

Salida

campo	valor
fecha_ejecucion	2026-10-20T14:25:49-03:00
python	3.14.8
sistema	Linux 7.2.10-100.fc43.x86_64
pandas	3.0.6
numpy	2.5.4
matplotlib	3.11.2
openpyxl	3.1.5
expediente	BES-jun
insumo	entrada/BES_jun.xlsx
insumo_sha256	ccb5a738baea13321993e8b6eccefd6cac90ecda86b1c4b9181f897fcfa83f85

Código

```
from ingesta.integridad import huellas
from ingesta.leer_bes_jun import COPIA_TRABAJO, leer_libro
sha_inicial = huellas(COPIA_TRABAJO)["sha256"]
hojas = leer_libro()
```

Paso 1 · Diccionario de variables

Qué se hace. Se declara, de forma explícita y en un solo lugar (`ingesta/mapeo.py`), qué variables se extraen y **cómo se localiza cada una**: por el texto de su rótulo, en qué columna está el rótulo, en cuál el valor y en cuál la unidad. **Por qué.** Un mapeo implícito (índices sueltos en el código) no es auditable. Aquí cada variable es una línea revisable: «el caudal de operación es la celda de la columna B de la fila cuyo rótulo en la columna A es *Caudal*, buscando desde la fila 60». La búsqueda desde la fila 60 evita confundirla con la celda «Caudal» del bloque de bomba, que está más arriba.

Código

```
from ingesta.mapeo import VARIABLES
dic = pd.DataFrame(VARIABLES, columns=["variable", "rótulo buscado", "col. rótulo", "col. valor", "col. unidad",
                                       "buscar desde fila", "n.º de aparición", "rol"])
dic["col. unidad"] = dic["col. unidad"].map(lambda v: "encabezado de tabla" if v is None else v)
print("Variables declaradas:", len(dic))
T(dic, ancha=True)
```

Salida

```
Variables declaradas: 34
```

Salida

variable	rótulo buscado	col. rótulo	col. valor	col. unidad	buscar desde fila	n.º de aparición	rol
frecuencia_hz	Velocidad	1	2	3	60	1	entrada de operación
caudal_operacion_bfpd	Caudal	1	2	3	60	1	entrada de operación
presion_sensor_psi	Presión de Sensor	1	2	3	60	1	entrada de operación
thp_psi	THP	1	2	3	60	1	entrada de operación
id_tubing_in	ID	1	2	3	1	1	parámetro mecánico
etapas	Etapas	1	2	3	1	1	parámetro de bomba
presion_yacimiento_psi	Presión de Yacimiento	5	7	8	1	1	parámetro de yacimiento
presion_burbuja_psi	Presión de Burbuja	5	7	8	1	1	parámetro de fluido
presion_prueba_psi	Presión de Prueba	5	7	8	1	1	dato de prueba
caudal_prueba_bfpd	Caudal de Prueba	5	7	8	1	1	dato de prueba
bsw_numero	BS&W	5	7	8	1	1	parámetro de fluido
temperatura_f	Temperatura de fondo	5	7	8	1	1	parámetro de fluido
temperatura_c	Temperatura de fondo	5	7	8	1	2	calculada en la hoja
api_deg	API	5	7	8	1	1	parámetro de fluido
densidad_agua_lb_gal	Densidad del Agua	5	7	8	1	1	parámetro de fluido
frecuencia_curva_hz	Velocidad	5	7	8	1	1	referencia de la curva de bomba
limite_minimo_bfpd	Limite minimo	5	7	8	1	1	límite escrito en la hoja
cono_eficiencia_bfpd	Cono de eficiencia	5	7	8	1	1	límite escrito en la hoja
limite_maximo_bfpd	Limite maximo	5	7	8	1	1	límite escrito en la hoja
md_descarga_ft	Descarga	1	2	—	1	1	parámetro mecánico
tvd_descarga_ft	Descarga	1	3	—	1	1	calculada en la hoja
md_intake_ft	Intake	1	2	—	1	1	parámetro mecánico
tvd_intake_ft	Intake	1	3	—	1	1	calculada en la hoja
md_sensor_ft	Sensor	1	2	—	1	1	parámetro mecánico
tvd_sensor_ft	Sensor	1	3	—	1	1	calculada en la hoja
cache_sg_60	Gravedad Oil @ 60ºF	1	2	3	60	1	resultado de la hoja
cache_sg_temperatura	Gravedad Oil @ T fondo	1	2	3	60	1	resultado de la hoja
cache_densidad_lb_gal	Densidad de Fluido	1	2	3	60	1	resultado de la hoja
cache_gradiente_psi_ft	Gradiente de Presión	1	2	3	60	1	resultado de la hoja
cache_pip_ft	PIP en (ft)	5	7	8	1	1	resultado de la hoja
cache_thp_ft	THP en (ft)	5	7	8	1	1	resultado de la hoja
cache_friccion_ft	Perdidad por Fricción	5	7	8	1	1	resultado de la hoja
cache_thd_ft	THD TOTAL	5	7	8	1	1	resultado de la hoja
cache_caudal_producir_bfpd	Caudal a producir	1	2	3	60	1	resultado de la hoja

Cómo leer la tabla. «n.º de aparición = 2» (caso de la temperatura en °C) significa que el rótulo «Temperatura de fondo» aparece dos veces —la primera en °F, la segunda en °C como fórmula— y se toma la segunda. Las variables con prefijo `cache_` son **resultados que la propia hoja calculó**; se extraen para poder contrastarlos con el código (cuaderno 04), no para usarlos como entradas.

Paso 2 · Ejecutar el mapeo: tabla larga con procedencia

La tabla larga tiene una fila por hoja y variable, con: celda de origen (`G26`), tipo de celda (**constante** escrita a mano o **fórmula** calculada por Excel), fórmula (si la hay), valor, unidad rotulada y rol. Para fórmulas el valor es el **guardado en caché** del último cálculo de Excel.

Código

```
from ingesta.mapeo import mapear
largo = pd.DataFrame(mapear())
print("Filas:", len(largo), "| hojas:", largo["hoja"].nunique(), "| variables:", largo["variable"].nunique(),
      "| celdas no encontradas:", int((largo["tipo_celda"] == "no encontrada").sum()))
print("Tipo de celda:", largo["tipo_celda"].value_counts().to_dict())
T(largo[largo["hoja"] == "QF-554H"][["variable", "rotulo", "celda", "tipo_celda", "valor", "unidad_rotulada",
"rol"]]
  .rename(columns={"rotulo": "rótulo en la hoja"}), ancha=True)
```

Salida

```
Filas: 170 | hojas: 5 | variables: 34 | celdas no encontradas: 0
Tipo de celda: {'constante': 102, 'fórmula': 68}
```

Salida

variable	rótulo en la hoja	celda	tipo_celda	valor	unidad_rotulada	rol
frecuencia_hz	Velocidad	B69	constante	63	Hz	entrada de operación
caudal_operacion_bfpd	Caudal	B71	constante	10301	BFPD	entrada de operación
presion_sensor_psi	Presión de Sensor	B73	constante	732	psi	entrada de operación
thp_psi	THP	B75	constante	183	psi	entrada de operación
id_tubing_in	ID	B38	constante	2.996	inch	parámetro mecánico
etapas	Etapas	B46	constante	53	Nº	parámetro de bomba
presion_yacimiento_psi	Presión de Yacimiento	G18	constante	1100	psi	parámetro de yacimiento
presion_burbuja_psi	Presión de Burbuja	G20	constante	130	psi	parámetro de fluido
presion_prueba_psi	Presión de Prueba	G22	constante	732	psi	dato de prueba
caudal_prueba_bfpd	Caudal de Prueba	G24	constante	10301	BFPD	dato de prueba
bsw_numero	BS&W	G26	constante	0.9755	%	parámetro de fluido
temperatura_f	Temperatura de fondo	G28	constante	150	ºF	parámetro de fluido
temperatura_c	Temperatura de fondo	G30	fórmula	65.555556	ºC	calculada en la hoja
api_deg	API	G32	constante	12	ºAPI	parámetro de fluido
densidad_agua_lb_gal	Densidad del Agua	G34	constante	8.345	Lb/gln	parámetro de fluido
frecuencia_curva_hz	Velocidad	G47	constante	60	Hz	referencia de la curva de bomba
limite_minimo_bfpd	Limite minimo	G56	constante	2500	BFPD	límite escrito en la hoja
cono_eficiencia_bfpd	Cono de eficiencia	G57	constante	8000	BFPD	límite escrito en la hoja
limite_maximo_bfpd	Limite maximo	G58	constante	10000	BFPD	límite escrito en la hoja
md_descarga_ft	Descarga	B18	constante	2841.51	ft (encabezado «MD (ft)»)	parámetro mecánico
tvd_descarga_ft	Descarga	C18	fórmula	2644.7775	ft (encabezado «TVD (ft)»)	calculada en la hoja
md_intake_ft	Intake	B20	constante	2856.1	ft (encabezado «MD (ft)»)	parámetro mecánico
tvd_intake_ft	Intake	C20	fórmula	2653.1767	ft (encabezado «TVD (ft)»)	calculada en la hoja
md_sensor_ft	Sensor	B24	constante	2900.58	ft (encabezado «MD (ft)»)	parámetro mecánico
tvd_sensor_ft	Sensor	C24	fórmula	2678.822	ft (encabezado «TVD (ft)»)	calculada en la hoja
cache_sg_60	Gravedad Oil @ 60ºF	B96	fórmula	0.98606272	—	resultado de la hoja
cache_sg_temperatura	Gravedad Oil @ T fondo	B98	fórmula	0.953813	—	resultado de la hoja
cache_densidad_lb_gal	Densidad de Fluido	B100	fórmula	8.3352064	Lb/Gln	resultado de la hoja
cache_gradiente_psi_ft	Gradiente de Presión	B102	fórmula	0.43343073	psi*ft	resultado de la hoja
cache_pip_ft	PIP en (ft)	G96	fórmula	1714.4965	ft	resultado de la hoja
cache_thp_ft	THP en (ft)	G98	fórmula	422.21279	ft	resultado de la hoja
cache_friccion_ft	Perdidad por Fricción	G100	fórmula	730.7232	ft	resultado de la hoja
cache_thd_ft	THD TOTAL	G102	fórmula	2083.217	ft	resultado de la hoja
cache_caudal_producir_bfpd	Caudal a producir	B106	fórmula	10535.167	BFPD	resultado de la hoja

Arriba se muestra la hoja QF-554H como ejemplo; las otras cuatro tienen la misma forma con **otra celda de origen** para cada variable. A continuación, la **matriz de entradas**: una variable por fila y una hoja por columna, para comparar de un vistazo las cinco condiciones de operación.

Código

```
matriz = largo.pivot(index="variable", columns="hoja", values="valor")[[h["hoja"] for h in hojas]]
matriz = matriz.loc[[v for v in dic["variable"]]].reset_index()
T(matriz, ancha=True)
```

Salida

variable	QF-554H	QF-545H	QF-500H	QF-378HST	QF-549HST
frecuencia_hz	63	57	56	67	62
caudal_operacion_bfpd	10301	8767	7728	7116	5419
presion_sensor_psi	732	667	821	810	607
thp_psi	183	210	194	145	177
id_tubing_in	2.996	2.996	2.996	2.996	2.996
etapas	53	50	36	31	31
presion_yacimiento_psi	1100	1100	1100	1100	1100
presion_burbuja_psi	130	130	130	130	130
presion_prueba_psi	732	654	821	810	607
caudal_prueba_bfpd	10301	8767	7728	7094.4	5419
bsw_numero	0.9755	0.9766	0.9644	0.9557	0.9557
temperatura_f	150	144	150	150	150
temperatura_c	65.555556	62.222222	65.555556	65.555556	65.555556
api_deg	12	12	12	12	12
densidad_agua_lb_gal	8.345	8.345	8.345	8.345	8.345
frecuencia_curva_hz	60	60	60	60	60
limite_minimo_bfpd	2500	2500	2500	2000	2000
cono_eficiencia_bfpd	8000	8000	8000	6000	6000
limite_maximo_bfpd	10000	10000	10000	8000	8000
md_descarga_ft	2841.51	2978.66	2801.9	3018.77	2787.17
tvd_descarga_ft	2644.7775	2527.362	2572.4604	2763.6426	2608.4579
md_intake_ft	2856.1	2994.87	2813.57	3028.46	2796.27
tvd_intake_ft	2653.1767	2534.6038	2578.9682	2769.6593	2614.0638
md_sensor_ft	2900.58	3038.12	2859.3	3061.68	2829.66
tvd_sensor_ft	2678.822	2553.9174	2604.4984	2790.2827	2634.6029
cache_sg_60	0.98606272	0.98606272	0.98606272	0.98606272	0.98606272
cache_sg_temperatura	0.953813	0.95591633	0.953813	0.953813	0.953813
cache_densidad_lb_gal	8.3352064	8.3360561	8.3307693	8.3272916	8.3272916
cache_gradiente_psi_ft	0.43343073	0.43347492	0.43320001	0.43301916	0.43301916
cache_pip_ft	1714.4965	1558.0416	1920.7287	1891.2104	1422.3246
cache_thp_ft	422.21279	484.4571	447.8301	334.85816	408.75789
cache_friccion_ft	730.7232	518.17768	417.64737	385.17249	219.61963
cache_thd_ft	2083.217	1971.9551	1517.2092	1592.4629	1814.5108
cache_caudal_producir_bfpd	10535.167	8280.8591	7360.156	7802.6082	5503.0344

Lectura rápida de la matriz. Las cinco hojas operan a frecuencias distintas de la de la curva (60 Hz), tienen entre 31 y 53 etapas y sus límites de caudal escritos son iguales por grupos (2500/8000/10000 en tres hojas; 2000/6000/8000 en dos), lo que corresponde a la misma referencia de bomba (cuaderno 06 lo verifica con las tablas). Falta mirar lo contrario: ¿qué **no varía** entre pozos?

Código

```
cols = [h["hoja"] for h in hojas]
fijas = matriz[matriz[cols].nunique(axis=1) == 1][["variable", cols[0]]].rename(columns={cols[0]: "valor
(igual en las 5 hojas)"})
fijas = fijas[~fijas["variable"].str.startswith("cache_")]
```

```
print("Variables de entrada con el mismo valor en las 5 hojas:", len(fijas))
T(fijas)
```

Salida

```
Variables de entrada con el mismo valor en las 5 hojas: 6
```

Salida

variable	valor (igual en las 5 hojas)
id_tubing_in	2.996
presion_yacimiento_psi	1100
presion_burbuja_psi	130
api_deg	12
densidad_agua_lb_gal	8.345
frecuencia_curva_hz	60

Hallazgo. °API (12), presión de yacimiento (1100 psi), presión de burbuja (130 psi), densidad del agua (8.345 lb/gal), ID del tubing (2.996 in) y la frecuencia de la curva son **idénticos en los cinco pozos**. Para el ID y la frecuencia de la curva es razonable (misma completación y misma tabla). Para °**API, yacimiento y burbuja** es llamativo: cinco pozos distintos con exactamente el mismo fluido y la misma presión de yacimiento sugiere valores de **plantilla** más que mediciones por pozo. No se concluye que estén mal; se registra como riesgo, porque °API alimenta directamente el gradiente (y con él PIP, THP y THD). Debe confirmarse con quien mantiene el libro si esos datos son propios de cada pozo.

Paso 3 · Prueba de ida y vuelta contra el libro

Qué se prueba. Que la tabla larga es una **copia fiel**. Se vuelve a abrir el libro y, para cada fila, se lee otra vez la celda indicada en `celda` y se compara con el `valor` de la tabla (el crudo si es constante; el guardado en caché si es fórmula). Si el mapeo hubiera redondeado, convertido o mal asignado algo, aparecería aquí. Es una prueba **independiente de la lógica de búsqueda**: usa solo la dirección de celda resultante.

Código

```
from openpyxl import load_workbook
wf = load_workbook(COPIA_TRABAJO, data_only=False)
wv = load_workbook(COPIA_TRABAJO, data_only=True)
diferencias = []
for fila in largo.itertuples():
    crudo, cache = wf[fila.hoja][fila.celda].value, wv[fila.hoja][fila.celda].value
    esperado = cache if fila.tipo_celda == "fórmula" else crudo
    if esperado != fila.valor:
        diferencias.append((fila.hoja, fila.variable, fila.celda, esperado, fila.valor))
wf.close(); wv.close()
print("Filas comprobadas:", len(largo), "| diferencias encontradas:", len(diferencias))
```

Salida

```
Filas comprobadas: 170 | diferencias encontradas: 0
```

Interpretación. Cero diferencias: cada valor de la tabla es **exactamente** el de su celda, con la misma precisión de punto flotante. El mapeo no transformó nada.

Paso 4 · Identificadores: hoja, Cluster y Pozo

El libro tiene tres textos que parecen identificar el registro: el **nombre de la hoja**, la celda **Cluster** y la celda **Pozo**. Antes de elegir una llave hay que ver si coinciden.

Código

```
ids = pd.DataFrame([{"hoja": h["hoja"], "Cluster": h["cluster"], "Pozo": h["pozo"],
                     "Cluster = hoja": h["cluster"] == h["hoja"], "llave compuesta usada": h["llave"]} for h
in hojas])
print("Pozos distintos:", ids["Pozo"].nunique(), "de", len(ids), "| Cluster = nombre de hoja en todas:",
```

```
bool(ids["Cluster = hoja"].all())
T(ids)
```

Salida

```
Pozos distintos: 5 de 5 | Cluster = nombre de hoja en todas: True
```

Salida

hoja	Cluster	Pozo	Cluster = hoja	llave compuesta usada
QF-554H	QF-554H	QF-084	sí	QF-554H|QF-084
QF-545H	QF-545H	QF-301	sí	QF-545H|QF-301
QF-500H	QF-500H	QF-147	sí	QF-500H|QF-147
QF-378HST	QF-378HST	QF-005	sí	QF-378HST|QF-005
QF-549HST	QF-549HST	QF-306	sí	QF-549HST|QF-306

Interpretación. `Cluster` repite el nombre de la hoja (no aporta información nueva) y `Pozo` es otro código. El libro **no declara cuál es la llave** del registro (CT-01). Mientras tanto el expediente identifica cada punto por la **hoja**, que es única y es lo único verificable, y conserva `Pozo` como texto. No se afirma que la hoja y el pozo sean equivalentes.

Paso 5 · Registro de unidades

Qué se hace. Para cada variable se reúnen los rótulos de unidad que las cinco hojas escriben. Si una variable tuviera rótulos distintos entre hojas, la unidad sería ambigua. Después se añade una **observación** donde el rótulo es engañoso. **Qué no se hace:** no se convierte ninguna unidad; el valor se conserva con el rótulo que trae la hoja, y la observación advierte cómo interpretarlo.

Código

```
OBSERVACION = {
    "bsw_numero": "Rótulo «%», pero el número es una fracción (0.96–0.98) y la fórmula lo usa como tal. No se
convierte (CT-02).",
    "cache_gradiente_psi_ft": "Rótulo «psi*ft»; por análisis dimensional es psi/ft (cuaderno 02).",
    "cache_densidad_lb_gal": "Rótulos «Lb/Gln» y «Lb/Galn» según la hoja: grafías de lb/gal.",
    "densidad_agua_lb_gal": "Rótulos «Lb/gln» y «Lb/galn» según la hoja: grafías de lb/gal.",
    "etapas": "Rótulo «Nº»: conteo adimensional.",
    "cache_sg_60": "Sin rótulo de unidad: gravedad específica, adimensional.",
    "cache_sg_temperatura": "Sin rótulo de unidad: gravedad específica, adimensional.",
}
ADIMENSIONALES = {"cache_sg_60", "cache_sg_temperatura"}
unidades = (largo.groupby("variable", sort=False)
            .agg(unidades_rotuladas=("unidad_rotulada", lambda s: " | ".join(sorted({str(u) for u in s if
pd.notna(u)})) or "—"),
                 n_rotulos_distintos=("unidad_rotulada", lambda s: len({u for u in s if pd.notna(u)})),
                 tipo_de_celda=("tipo_celda", lambda s: " | ".join(sorted(set(s)))))
            .reset_index())
unidades["observación"] = unidades["variable"].map(OBSERVACION).fillna("")
sin_unidad = [v for v, u in zip(unidades["variable"], unidades["unidades_rotuladas"]) if u == "—"]
print("Variables con más de un rótulo de unidad entre hojas:", int((unidades["n_rotulos_distintos"] >
1).sum()))
print("Variables sin rótulo de unidad:", sin_unidad)
T(unidades.drop(columns="n_rotulos_distintos"), ancha=True)
```

Salida

```
Variables con más de un rótulo de unidad entre hojas: 2
Variables sin rótulo de unidad: ['cache_sg_60', 'cache_sg_temperatura']
```

Salida

variable	unidades_rotuladas	tipo_de_celda	observación
frecuencia_hz	Hz	constante	
caudal_operacion_bfpd	BFPD	constante | fórmula	
presion_sensor_psi	psi	constante	
thp_psi	psi	constante	
id_tubing_in	inch	constante	

variable	unidades_rotuladas	tipo_de_celda	observación
etapas	Nº	constante	Rótulo «Nº»: conteo adimensional.
presion_yacimiento_psi	psi	constante	
presion_burbuja_psi	psi	constante	
presion_prueba_psi	psi	constante	
caudal_prueba_bfpd	BFPD	constante | fórmula	
bsw_numero	%	constante	Rótulo «%», pero el número es una fracción (0.96–0.98) y la fórmula lo usa como tal. No se convierte (CT-02).
temperatura_f	ºF	constante	
temperatura_c	ºC	fórmula	
api_deg	ºAPI	constante	
densidad_agua_lb_gal	Lb/galn | Lb/gln	constante	Rótulos «Lb/gln» y «Lb/galn» según la hoja: grafías de lb/gal.
frecuencia_curva_hz	Hz	constante	
limite_minimo_bfpd	BFPD	constante	
cono_eficiencia_bfpd	BFPD	constante	
limite_maximo_bfpd	BFPD	constante	
md_descarga_ft	ft (encabezado «MD (ft)»)	constante	
tvd_descarga_ft	ft (encabezado «TVD (ft)»)	fórmula	
md_intake_ft	ft (encabezado «MD (ft)»)	constante	
tvd_intake_ft	ft (encabezado «TVD (ft)»)	fórmula	
md_sensor_ft	ft (encabezado «MD (ft)»)	constante	
tvd_sensor_ft	ft (encabezado «TVD (ft)»)	fórmula	
cache_sg_60	—	fórmula	Sin rótulo de unidad: gravedad específica, adimensional.
cache_sg_temperatura	—	fórmula	Sin rótulo de unidad: gravedad específica, adimensional.
cache_densidad_lb_gal	Lb/Galn | Lb/Gln	fórmula	Rótulos «Lb/Gln» y «Lb/Galn» según la hoja: grafías de lb/gal.
cache_gradiente_psi_ft	psi*ft	fórmula	Rótulo «psi*ft»; por análisis dimensional es psi/ft (cuaderno 02).
cache_pip_ft	ft	fórmula	
cache_thp_ft	ft	fórmula	
cache_friccion_ft	ft	fórmula	
cache_thd_ft	ft	fórmula	
cache_caudal_producir_bfpd	BFPD	fórmula	

Interpretación. Solo dos variables muestran más de un rótulo entre hojas, y son **grafías de la misma unidad** (lb/gal escrita «Lb/gln», «Lb/galn» o «Lb/Gln»): no hay ambigüedad física. Dos variables no tienen rótulo y son gravedades específicas (adimensionales por definición). Tres rótulos merecen advertencia —`BS&W «%»`, `gradiente «psi*ft»` y las grafías de lb/gal—. Además, el caudal de operación y el de prueba son **constante en unas hojas y fórmula en otra** (columna «tipo de celda»): es la hoja con el factor 24 (CT-07). Esta tabla es la que debe consultar quien lea un resultado: indica no solo la unidad, sino **cuándo no creer el rótulo**.

Paso 6 · Datos de prueba frente a datos de operación

Cada hoja trae un caudal y una presión «de prueba» además de los de «operación». Si fueran iguales, la hoja no tendría información de **dos momentos**; si difieren, hay que saber cuánto. Es información relevante para evaluar (cuaderno 05) y para detectar celdas con fórmulas escondidas (CT-07).

Código

```
filas = []
for h in hojas:
    sub = largo[largo["hoja"] == h["hoja"]].set_index("variable")
    filas.append({"hoja": h["hoja"],
                  "Q prueba (BFPD)": h["caudal_prueba_bfpd"], "Q operación (BFPD)":
```

```
h["caudal_operacion_bfpd"],
                  "diferencia Q (%)": 100 * (h["caudal_operacion_bfpd"] - h["caudal_prueba_bfpd"]) /
h["caudal_prueba_bfpd"],
                  "P prueba (psi)": h["presion_prueba_psi"], "P sensor (psi)": h["presion_sensor_psi"],
                  "tipo de celda Q prueba": sub.loc["caudal_prueba_bfpd", "tipo_celda"],
                  "fórmula de Q prueba": sub.loc["caudal_prueba_bfpd", "formula"] or "—"})
prueba = pd.DataFrame(filas)
T(prueba, ancha=True)
```

Salida

hoja	Q prueba (BFPD)	Q operación (BFPD)	diferencia Q (%)	P prueba (psi)	P sensor (psi)	tipo de celda Q prueba	fórmula de Q prueba
QF-554H	10301	10301	0	732	732	constante	—
QF-545H	8767	8767	0	654	667	constante	—
QF-500H	7728	7728	0	821	821	constante	—
QF-378HST	7094.4	7116	0.30446549	810	810	fórmula	=295.6*24
QF-549HST	5419	5419	0	607	607	constante	—

Interpretación. En las hojas donde el caudal de prueba coincide con el de operación, los datos de «prueba» y de «operación» **son el mismo punto**: no hay dos momentos que comparar. La excepción es la hoja cuya celda de prueba es una **fórmula** con un factor 24 sin definir (CT-07): allí prueba y operación difieren en una fracción de porcentaje. Además, en QF-545H la presión de prueba (654 psi) difiere de la del sensor (667 psi) con el mismo caudal. El expediente usa siempre los valores de **operación**; no redefine los de prueba.

Paso 7 · Guardar las tablas y verificarlas

Se escriben tres CSV en `data_procesados/` y se **releen** para comprobar que lo guardado es lo calculado. Un archivo que no se relee es un archivo del que se asume que está bien.

Código

```
import numpy as np
destino = RAIZ / "data_procesados"
largo.to_csv(destino / "variables_largo.csv", index=False)
matriz.to_csv(destino / "matriz_entradas_por_hoja.csv", index=False)
unidades.to_csv(destino / "registro_unidades.csv", index=False)

rel_largo = pd.read_csv(destino / "variables_largo.csv")
rel_matriz = pd.read_csv(destino / "matriz_entradas_por_hoja.csv")
rel_uni = pd.read_csv(destino / "registro_unidades.csv")
valores_ok = np.allclose(pd.to_numeric(rel_largo["valor"], errors="coerce").to_numpy(),
                         pd.to_numeric(largo["valor"], errors="coerce").to_numpy(), rtol=1e-12, atol=0,
equal_nan=True)
csv_ok = (rel_largo.shape == largo.shape and rel_matriz.shape == matriz.shape and rel_uni.shape ==
unidades.shape
          and valores_ok and list(rel_largo["celda"]) == list(largo["celda"]))
print("Archivos escritos:", [p.name for p in sorted(destino.glob("*.csv")) if p.name in
      ("variables_largo.csv", "matriz_entradas_por_hoja.csv", "registro_unidades.csv")])
print("Relectura idéntica a lo escrito:", "SÍ" if csv_ok else "NO")
```

Salida

```
Archivos escritos: ['matriz_entradas_por_hoja.csv', 'registro_unidades.csv', 'variables_largo.csv']
Relectura idéntica a lo escrito: SÍ
```

Paso 8 · Política de transformaciones

Operación	¿Se hizo?	Detalle
Cambiar de formulario a tabla larga	**Sí**	Una fila por hoja y variable, con celda de origen.
Convertir unidades (p. ej. °F → °C, % → fracción)	**No**	El valor se conserva con su rótulo. La temperatura en °C es la celda de **fórmula** de la propia hoja, no una conversión nuestra.

Operación	¿Se hizo?	Detalle
Imputar o rellenar faltantes	**No**	No hay faltantes (cuaderno 01); si los hubiera, la variable queda vacía.
Redondear o normalizar	**No**	Precisión de punto flotante completa.
Eliminar filas, outliers o hojas	**No**	Se conservan las cinco hojas.
Unir hojas	**No**	Cada hoja es un punto de operación aislado; no se construye una «serie».
Guardar el libro	**No**	`openpyxl` solo lee; el SHA-256 se verifica al final.

Esta política es deliberadamente conservadora: **ante la duda, se registra y se pregunta; no se corrige en silencio**. Cualquier transformación futura debe añadirse a esta tabla antes de aplicarse.

Paso 9 · Criterios de aceptación

Código

```
crit = Criterios("03_limpieza_y_mapeo")
n_comunes = 0
for h in hojas:
    sub = largo[largo["hoja"] == h["hoja"]].set_index("variable")["valor"]
    for clave, valor in h.items():
        if clave in sub.index and isinstance(valor, (int, float)) and isinstance(sub[clave], (int, float)):
            n_comunes += 1
            if abs(float(sub[clave]) - float(valor)) > 1e-12:
                diferencias.append((h["hoja"], clave, "lector", valor, sub[clave]))
crit.comprobar("C03-1", "170 filas y ninguna celda sin encontrar", len(largo) == 5 * len(VARIABLES) == 170
               and int((largo["tipo_celda"] == "no encontrada").sum()) == 0, f"{len(largo)} filas")
crit.comprobar("C03-2", "Mapeo = lector en las variables comunes", n_comunes > 100 and not [d for d in
diferencias if d[2] == "lector"],
               f"{n_comunes} valores comparados")
crit.comprobar("C03-3", "Ida y vuelta contra el libro sin diferencias", not [d for d in diferencias if d[2] !=
"lector"],
               f"{len(largo)} celdas releídas")
crit.comprobar("C03-4", "CSV releídos idénticos a lo escrito", csv_ok, "3 archivos")
crit.comprobar("C03-5", "Toda variable tiene unidad o está declarada adimensional", set(sin_unidad) <=
ADIMENSIONALES,
               f"sin rótulo: {sin_unidad}")
crit.comprobar("C03-6", "El libro no cambió", huellas(COPIA_TRABAJO)["sha256"] == sha_inicial,
sha_inicial[:16] + "…")
T(crit.tabla())
```

Salida

id	criterio	resultado	evidencia
C03-1	170 filas y ninguna celda sin encontrar	CUMPLE	170 filas
C03-2	Mapeo = lector en las variables comunes	CUMPLE	145 valores comparados
C03-3	Ida y vuelta contra el libro sin diferencias	CUMPLE	170 celdas releídas
C03-4	CSV releídos idénticos a lo escrito	CUMPLE	3 archivos
C03-5	Toda variable tiene unidad o está declarada adimensional	CUMPLE	sin rótulo: ['cache_sg_60', 'cache_sg_temperatura']
C03-6	El libro no cambió	CUMPLE	ccb5a738baea1332…

Código

```
crit.exigir()
print("Todos los criterios de aceptación del cuaderno 03 se cumplen.")
```

Salida

```
Todos los criterios de aceptación del cuaderno 03 se cumplen.
```

Conclusión técnica

- **Resultado:** quedó una tabla larga de 170 filas con la celda de origen de cada número, comprobada celda por celda contra el libro, y un registro de unidades que advierte los tres rótulos engañosos.
- **Qué habilita:** cualquier valor que aparezca en un informe puede rastrearse hasta una celda concreta de una hoja concreta del archivo identificado por su SHA-256.
- **Lo que no se resolvió (y se declara):** la llave del registro (CT-01); la unidad real de BS&W (CT-02); el significado del factor 24 (CT-07).
- **Límites:** el mapeo localiza por rótulo; si una versión futura del libro cambiara un rótulo, la variable aparecería como «no encontrada» y el criterio C03-1 detendría la ejecución, en lugar de leer otra celda sin avisar.
- **Siguiente paso:** cuaderno 04, ejecución de la cadena de cálculo y contraste de cada paso intermedio con la hoja.

Relación con el sistema de reglas

Fija el nombre y la unidad con los que cada variable se guarda, y demuestra que el valor no se alteró al mapearlo. Ese nombre canónico es el de `integracion/variables.json`. No define límites de operación.

Limitaciones

- El mapeo localiza celdas por rótulo y valida con una prueba de ida y vuelta; no corrige rótulos incorrectos (los registra).
- No se convierten unidades ni se imputan datos: la tabla es tan buena como el libro.
- La tabla larga contiene 34 variables elegidas por su uso en el cálculo; otras celdas del libro no se mapean.
- Los parámetros idénticos entre hojas se señalan; si son datos de plantilla o de pozo no puede decidirse con el libro (CT-10).

Referencias

Solo se listan las fuentes realmente consultadas en este cuaderno.

1. **Libro de trabajo:** `entrada/BES_jun.xlsx`, copia byte a byte de «Copia de FINAL BES-jun.xlsx» (SHA-256 `ccb5a738baea13321993e8b6eccefd6cac90ecda86b1c4b9181f897fcfa83f85`). Cinco hojas: QF-554H, QF-545H, QF-500H, QF-378HST y QF-549HST.
2. **`docs/consultas_tecnicas_pendientes.md`** (expediente): registro CT-01…CT-10 de ambigüedades abiertas.
3. **Software:** Python 3.14.8, pandas 3.0.6, numpy 2.5.4, matplotlib 3.11.2, openpyxl 3.1.5 (versiones tomadas de la ficha de entorno de cada ejecución).